塝定律：面向人工具身智能的离散组合推理范式

从连续向量生成到离散检索—拼装

四川庄周梦蝶文化科技有限公司

作者：闵安娜 李哲 阳景宏 （17742898391@163.com）

2026 年 10 月 10 日

摘要

近十年，以连续向量表征与权重前推为核心范式的深度学习、大语言模型与端到端具身模型，在感知、语言与低层控制上取得了决定性进展。然而，当任务从"通用知识的复述"转向"复杂个体决策"与"长程具身操作"时，这一范式暴露出结构性的边界：输出概率化、决策路径黑箱化、推理成本高昂、同一输入难以稳定复现，且难以审计与安全验证。其症结不在于模型规模，而在于首要优化目标本身——系统一直在连续向量空间中"拟合"，而非在离散组合空间中"映射"。

本文提出坍定律：以离散组合空间替代连续向量空间，作为系统演进的首要优化目标。其核心操作是——将输入锚定到有限、可穷举、确定性的离散状态空间，通过检索与确定性拼装生成输出，而非每次从连续权重前推生成。本文将坍定律表述为一条可分层、可度量、可证伪的系统演进原则，给出其形式化定义、分层架构、度量体系、技术路径、前瞻验证方案、落地路线图与开放挑战，并以个性化内容与自我探索场景中的早期实例（8 位体验者、17 天，核对符合率 97.1%），以及人工具身智能的高层规划与技能组合为主要应用方向。

本文的核心主张是：离散组合不是连续推理的替代品，而是其上层骨架与确定性锚点。真正的竞争力来自可验证的离散单元、正交覆盖、组合算法，以及"离散为骨、连续为肉"的混合工程能力。本文的定位是工程方法论与产业路线图，不主张为物理定律或科学预测理论。我们以本文同时作为一份来自工程一线的报告，与一份面向产业界的协作邀请。

关键词：坍定律；离散组合；连续向量推理；人工具身智能；确定性引擎；混合架构；组合泛化

1 引言

1.1 连续向量范式的成就与边界

自深度学习的复兴以来，以连续向量表征为基石的技术路线持续重塑着人工智能的边界。从卷积网络对视觉特征的层次化提取，到 Transformer 对序列依赖的注意力建模（Vaswani et al., 2017），再到视觉—语言—动作（VLA）端到端模型把感知、语言与控制在同一参数空间内联合训练，这一范式在感知、语言与低层控制上不断刷新上限。其方法论内核高度统一：把一切输入映射为高维连续向量，再通过可微的权重前推，把输出表示为概率分布。这一内核的可扩展性与通用性，正是过去十年进展的主要来源。

值得强调的是，这一范式的成功并非偶然，而建立在一个强假设之上：只要模型足够大、数据足够多，任何任务都可以被"通用地"逼近。在这一假设下，"更大"被等同于"更强"，而"更换度量"则被视为不必要的风险。于是行业形成了一种惯性——面对任何能力缺口，第一反应都是继续放大模型。这一惯性在通用任务上屡屡奏效，却遮蔽了一个事实：当一种度量逼近其边际收益边界时，真正的进展往往来自更换度量本身，而非把旧度量推到极致。

1.2 "泛化有余，精细不足"：具身智能与个体决策的共同瓶颈

一个耐人寻味的现象是，两类表面上相距遥远的任务——家庭服务机器人与个体心理/决策辅助——遭遇了同一个瓶颈。我们将其概括为"泛化有余，精细不足"。

在个体决策场景中，大语言模型（Brown et al., 2020）虽然掌握海量通用知识，但在面对职业转型、人际冲突、情绪底层归因等复杂问题时，往往给出"正确的废话"：表述通顺、逻辑自洽，却对具体个体缺乏针对性，且计算成本高、易产生幻觉。用户得到的不是"属于我的判断"，而是"关于一般人的常识"。在具身场景中，端到端模型虽然具备较强的通用感知与语言理解能力，但在长程任务上表现出技能复用差、组合泛化弱、实时性受限、安全验证困难等特征：当任务需要把若干已掌握的技能以新方式组合时，模型常常无法可靠地迁移；当环境出现训练分布之外的组合时，模型可能停滞或输出危险动作。

两类任务的共同点在于：它们的关键难点都不是"知道得不够多"，而是"把一个具体对象/任务稳定地映射到一个确定的、可执行的解"。前者需要从个体到决策的唯一映射，后者需要从任务到技能序列的唯一映射。连续向量范式擅长的"泛化"，恰恰在这里退化为"弥散"——它给出的是一个宽泛的概率云，而非一个确定的落点。这一观察构成了本文的出发点：问题不在"知道多少"，而在"如何确定地落地"。

1.3 核心问题：应该缩放什么，以什么为目标？

面对上述瓶颈，行业的惯性反应是继续放大模型。但正如度量史反复揭示的：当一种度量逼近其物理或经济边界时，真正的进展来自更换度量本身。因此，本文认为应当把问题从"模型还能不能更大"改写为：

应当缩放什么，以什么为目标？

本文的回答是：从连续向量空间转向离散组合空间，以确定性的检索—拼装替代概率生成，作为系统演进的首要优化目标。

这一回答包含两层含义。其一，"缩放"的对象发生改变——不再主要缩放参数量与算力，而是缩放离散状态的覆盖完备性、组合规则的可复用性与检索拼装的确定性。其二，"目标"发生改变——不再以"在连续空间中的拟合误差最小"为目标，而以"在离散空间中的映射唯一、组合可解释、输出可复现"为目标。

1.4 本文贡献与结构

本文的贡献如下：

1. 提出塝定律的定义与分层框架：以离散组合空间替代连续向量空间作为首要优化目标，并给出单元、技能、任务、系统四层的统一表述。
2. 给出度量体系与前瞻验证方案：以可证伪的硬指标度量"离散化程度"，并设计对照实验与失败判据。
3. 给出落地场景与产业路线图：以个性化内容/自我探索为近期锚点，以人工具身智能为中期方向，以全栈混合为远期目标。
4. 列出开放挑战，邀请产业协作：明确工具链、标准、基准、语料与安全验证等需要跨组织共建的议题。

本文其余部分组织如下：第 2 节剖析连续向量范式的结构性困境；第 3 节给出塝定律的定义、形式化与核心命题；第 4 节给出分层架构；第 5 节给出度量体系；第 6 节讨论技术路径与关键构件；第 7 节给出前瞻验证方案；第 8 节给出落地场景与路线图；第 9 节列出开放挑战；第 10 节总结并发出协作邀请。

1.5 为什么是现在

任何范式转换都需要时机。塝定律之所以在当下被提出，而非更早或更晚，源于三个条件的同步成熟：其一，连续向量范式的边际收益开始显现衰减——规模继续放大带来的能力提升，正让位于成本与能耗的急剧上升；其二，端侧具身与个体化服务的需求快速增长，二者都对"确定性、低算力、可审计"提出了硬性要求；其三，离散化基础设施经过多年积累已初具规模（特征工程、技能库、组合算法、规则引擎），使规模化部署成为可能。三者叠加，使"换坐标"从一种理论选项，变成一种现实可行的工程选择。

2 连续向量范式的结构性困境

2.1 概率输出与不确定性

连续向量范式的输出本质上是概率分布。对同一输入进行多次调用，输出在语义与结构上均可能发生漂移。这在创作、闲聊等场景中是可接受乃至有益的多样性，但在需要稳定复现的场景中则是缺陷：个体决策辅助要求"同一状态给出同一结构"，具身控制要求"同一指令产生同一行为"。当一致性本身成为功能要求时，概率输出从特性变为负担。

更深一层，概率输出使责任归属变得困难。当系统给出的建议引发后果时，工程师无法回答"它为什么会这样输出"——因为输出并非由某条可指认的规则产生，而是由数十亿参数的联合分布采样得出。在需要问责与合规的场景中，这种不可指认性本身就是风险。

2.2 黑箱权重与可解释性

连续向量系统的决策依据分布在数十亿乃至上千亿参数之中，无法被显式追踪。这带来两个后果：其一，可解释性缺失——当输出出现偏差时，难以定位是哪个环节、哪条规则所致；其二，认证困难——在安全关键场景（医疗、金融、物理操作）中，监管与工程都要求可审核的决策路径，而黑箱权重难以满足。可解释性并非锦上添花，而是安全关键系统的入场券。

需要区分两类可解释性："事后解释"（对黑箱输出做事后归因）与"结构可解释"（系统的决策规则本身就显式可读）。前者只能逼近真相，后者才能被审计。塝定律追求的正是后者。

2.3 算力成本与实时性

权重前推推理的算力与能耗随规模快速上升。行业观察普遍指出，现代 AI 系统的能量与成本预算越来越多地被数据搬运而非计算所主导（Horowitz, 2014）。在具身场景中，这一矛盾更为尖锐：端侧设备的功耗与散热预算有限，而控制回路往往要求在毫秒级周期内完成决策。大规模前推推理与端侧实时控制之间存在结构性张力。

这一张力意味着：即便模型能力持续提升，其在端侧实时场景中的可用性仍受限于算力与能耗的硬约束。把决策从"每次前推"改为"检索预计算结果"，正是缓解这一张力的直接手段。

2.4 组合泛化与长尾脆性

端到端模型对训练分布内样本表现优异，但对未见过的组合泛化能力有限。这一现象在认知科学中被反复讨论：连接主义系统擅长模式拟合，却在系统性的符号组合（systematicity）上存在先天不足（Fodor & Pylyshyn, 1988；Marcus, 2001；Lake & Baroni, 2018）。在开放环境中，这一缺陷可能表现为：遇到未定义的任务组合时卡死，或在缺乏约束时输出危险动作。

组合泛化的困难有结构性的根源：当系统以"整体拟合"方式学习时，它并未显式地学到"单元"与"组合规则"——因此无法在未见组合上复用已学单元。而离散组合范式恰恰把"单元"与"规则"显式化，从而使组合泛化从"期望涌现"变为"可被设计与检验"。

2.5 隐私与合规压力

连续向量范式的强表现往往依赖大量个人数据的训练与长上下文输入。随着数据保护法规（如 GDPR）对敏感个人数据日趋严格，依赖海量个体数据的路线面临越来越高的合规成本。一种更具隐私优势的路径，应当只需极少的客观参数即可完成个体锚定，而不依赖敏感身份信息或长篇隐私日志。

隐私优势不只是合规成本问题，更是产品信任问题。当系统以"抽象特征拓扑映射"替代"敏感数据上传"时，用户的心理负担显著降低，这在个体决策辅助这类高信任门槛的场景中尤为关键。

2.6 范式代价的结构性来源

上述困境并非某一模型的实现瑕疵，而是连续向量范式在设计选择上的必然代价，其根源可归结为三点：

- 表征的连续性：以连续向量承载一切信息，天然带来输出的连续性与概率性；确定性必须被额外"逼"出来，而非结构自带。
- 优化的整体性：以端到端拟合为优化方式，把"单元"与"规则"都消融进权重，使可解释性与可复用性成为事后补偿。
- 进化的同质性：以"放大规模"为唯一演进手段，使不同层的瓶颈无法被分别识别与投资。

垂定律正是针对这三点给出的替代方案：用离散替代连续、用显式组合替代整体拟合、用分层度量替代单一缩放。这一对应关系贯穿全文。

3 离散组合：新的优化坐标

3.1 核心定义：垿定律

垿定律：一种以离散组合替代连续向量推理的系统演进原则。其核心操作是——从有限、可穷举、确定性的离散状态空间中，检索并拼装结果，而非从连续向量空间中通过权重前推生成结果。

换言之，垿定律主张把系统演进的首要优化目标，从"在连续向量空间中的拟合精度"，切换为"在离散组合空间中的映射完备性与拼装确定性"。这与"以新坐标替换旧坐标"的思路一致：当旧坐标的边际收益衰减时，换坐标本身即是进展。

3.2 形式化表达

连续向量范式可写为：

$$y = f_\theta(x)$$

其中 θ 由梯度下降在连续参数空间中拟合，输出 y 为概率分布。

垿定律路径可写为：

$$y = \mathrm{Compose}(\ \mathrm{Retrieve}(\ \mathrm{Anchor}(x), M\ ), C\ )$$

其中：

- Anchor（锚定函数）：将输入 x 映射到离散状态空间中的唯一拓扑点；
- M（离散矩阵/技能库）：有限、可穷举、确定性的离散单元集合；
- Compose（组合规则）：按显式、可版本化的规则，把检索结果与上下文拼装为输出。

形式化地，连续范式的核心是"拟合一个函数"，垿定律的核心是"确定一次映射并完成一次拼装"。前者把不确定性留在输出层，后者把确定性前置到锚定与规则层（两种推理路径的对比如图 1 所示）。

为使上述形式化可操作，本文给出如下定义（涉及工程实现的部分标注为"待验证"）。

定义 1（离散状态空间） 设有 k 个控制变量 v1, …, vk，每个 vi 取值于有限集 Di。离散状态空间为笛卡尔积 S = D1 × … × Dk，其规模 |S| = |D1| × |D2| × … × |Dk|。S 有限且可穷举，这就是"有限、可穷举、确定性"的严格含义。

定义 2（垿离散单元） 一个垿离散单元为五元组 u = (id, type, payload, pre, post)：id 为唯一标识；type 取值为 {原子技能, 符号谓词, 特征原型, 预计算嵌入, 状态机节点} 之一；payload 为内容；pre/post 为前置/后置条件。

定义 3（锚定函数） 锚定函数 a: X → S 把输入 x 映射为状态空间中的点 s = a(x)。本文要求 a 满足弱唯一性：对目标域中的绝大多数 x，其原像 a^(-1)(a(x)) 的规模有界（理想为 1）。工程上 a 可由分层查表（先粗后细）、最近邻或规则匹配实现；对处于原型交界处的样本，采用阈值判定并显式标注为"不确定"，而非强行归类。

定义 4（组合规则） 组合规则集 C 为一组可版本化的产生式 u1, …, um → y；组合过程等价于在单元图上的一次搜索（见 9.1）。规则显式、可回滚，是"确定性输出"的来源。

定义 5（世代规则） 记 坍_n 为第 n 代的离散化程度，则 坍_{n+1} = α • √坍_n，α 为与应用相关的加速系数。

需要说明：以上定义刻画的是"目标形态"。其中正交性（定义 1 中 vi 的相互独立）与唯一性（定义 3）目前尚无独立数学证明，应按"待验证"对待（见 9.3）；在证明之前，本文不主张覆盖完备性已被证实。

图 1 两种推理路径：连续向量生成 vs. 离散检索—拼装

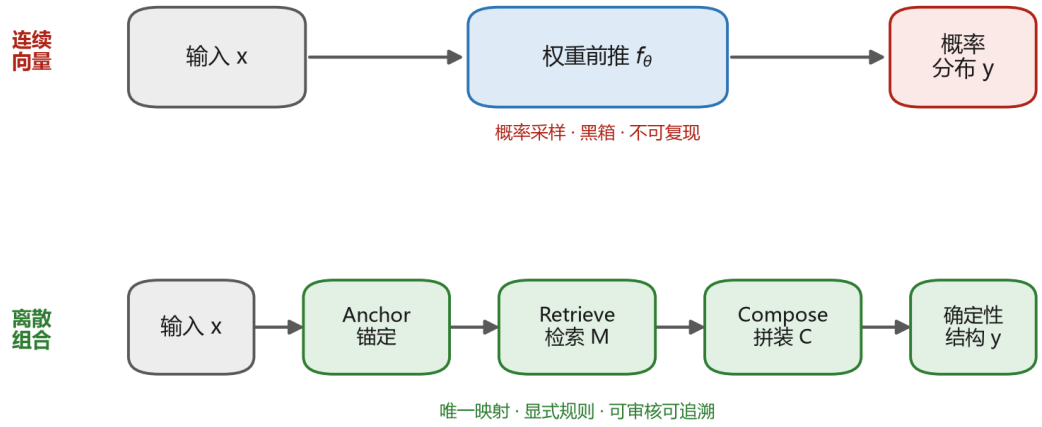


图 1 两种推理路径：连续向量生成 vs. 离散检索—拼装

3.3 四个核心转换

坍定律可被概括为四个核心转换：

1. 从"连续拟合"到"离散映射"：不追求权重逼近，而追求用户/任务到离散状态空间的唯一映射。
2. 从"生成"到"检索+拼装"：如同从固定地点提取预计算结果后直接拼装，而非每次重新前推生成。
3. 从"概率输出"到"确定性输出"：同样输入永远得到同样结构，内容可审核、可追溯。
4. 从"黑箱权重"到"可解释规则"：组合规则显式化，单元可审计、可复用。

3.4 分层坍

如同任何可工程化的优化目标，坍是分层的。我们将其表述为：

坍 = f(坍_unit, 坍_skill, 坍_task, 坍_system)

- 单元层（坍_unit）：原子技能/特征原型的离散度；
- 技能层（坍_skill）：技能组合路径的长度与可达性；
- 任务层（坍_task）：任务规划与检索深度；
- 系统层（坍_system）：端到端组合时延与一致性。

每一层的坍由下层单元与层间组织/通信开销共同构成。分层的意义在于：它使不同专业角色（单元设计者、技能编排者、任务规划者、系统架构师）能够用同一个量在同一单位下对

话，从而使端到端协同优化成为可能。当各层各自优化不同目标时，时间/性能往往作为"残差"出现；分层塝把这一残差显式化，使其可被主动优化（分层结构如图 2 所示）。



图 2 分层塝：单元 → 技能 → 任务 → 系统

3.5 世代规则

我们提出一条世代演进规则：

$$塝_{n+1} = \alpha \cdot \sqrt{塝_n}$$

其中下标 n、n+1 分别表示当前世代与下一世代，α 为与应用相关的加速系数。与"一刀切"的缩放不同，α 因场景而异：对内容类应用，α 可较低；对具身实时任务，α 需较高。世代规则的价值在于，它把一个抽象的"离散化程度"目标，转化为可被各层工程团队共同追求、并可被定期检验的量（世代演进如图 3 所示）。

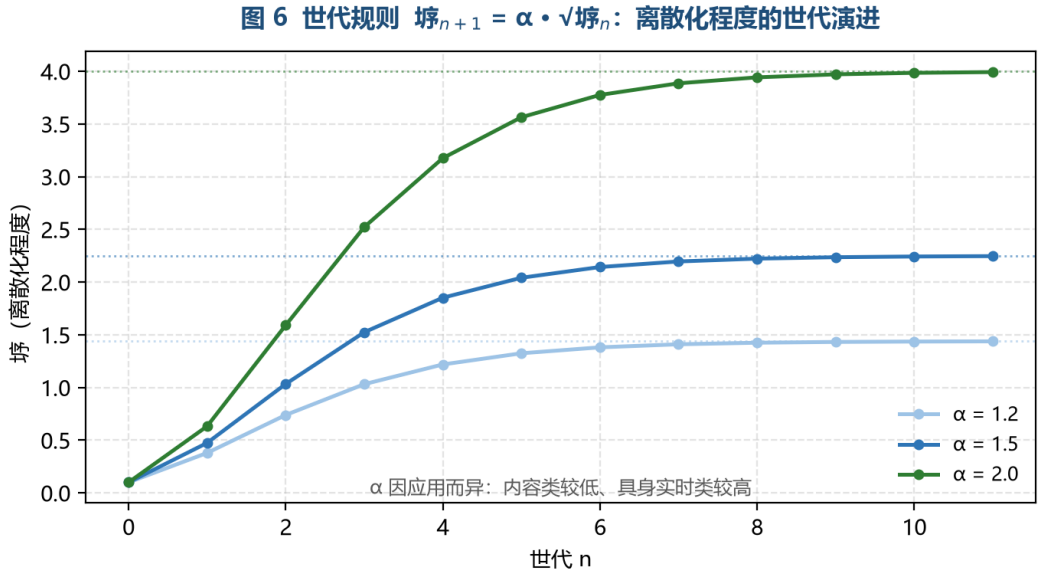


图 3 世代规则：离散化程度的世代演进

3.6 与连续推理的关系：离散为骨、连续为肉

塝定律并不主张完全抛弃连续推理。相反，它主张一种分层分工：

- 离散组合承担骨架、锚定、检索与审计：它保证结构确定、路径可解释、结果可复现；
- 连续推理承担感知接地、底层控制与语言润色：它把离散符号与连续物理世界、自然语言表达对接。

二者互补而非替代。这一分工的边界是明确的：纯离散适合封闭任务集（状态空间可穷举、规则可显式化）；开放环境则需连续推理接地，以处理未被离散化覆盖的连续量（力控、柔顺、接触等）。第 6.6 节将进一步讨论这一边界。

3.7 与相邻范式的边界

塝定律与若干既有路线存在交集，但其主张与之有明确边界，澄清这些边界有助于准确理解本原则：

- 与符号主义（GOFAI）：符号主义同样主张显式符号与规则（Newell & Simon, 1976），但其符号库往往依赖人工编码、缺乏可扩展的覆盖机制；塝定律强调用正交变量体系系统性地生成离散空间，使覆盖完备性成为可度量的工程目标。
- 与神经符号（neuro-symbolic）：神经符号通常以连续模型作为符号的接地层；塝定律更进一步，把离散组合提升为首要优化目标，连续推理退居"接地与执行"的辅助位。
- 与检索增强生成（RAG）：RAG 在连续生成的框架内引入检索，检索结果仍经概率拼装；塝定律的检索结果是确定性组合规则的输入，输出结构不依赖采样。
- 与程序合成/规划（program synthesis / planning）：程序合成追求由规约生成程序，与塝定律的"组合规则"思路相通；塝定律的差异在于，它把合成对象扩展为跨内容与具身的通用离散单元，并要求覆盖完备性与正交性可被度量。
- 与行为树（behavior tree）等经典具身方法：行为树是离散、可解释的（Brooks, 1990），但通常手工设计、缺乏从输入到状态的可扩展锚定机制；塝定律补上的正是锚定与覆盖这一环。

概括而言，塝定律的独特主张不是"离散优于连续"这一口号，而是把离散覆盖、正交变量、唯一锚定、确定性组合作为一套可分层度量、可工程验证的统一目标。

需要说明：上述为定性区分。真正界定边界需要定量对照——在统一任务集上比较各范式的成功率、泛化率、时延与可解释性，这属于本文之后的实验工作（见第 7 章）。在完成该对照之前，本文不主张塝定律已在工程上优于上述任一范式。

3.8 塝定律不是三件事

为避免误读，有必要明确塝定律不是什么：

- 它不是对连续推理的否定：连续推理仍是感知接地、底层控制与语言表达的必要手段，塝定律主张的是分层分工，而非全盘替代。
- 它不是对"规模"的否定：离散空间的建设同样需要规模化的工程投入（语料、技能库、规则），只是投入的方向从"参数"转向"覆盖与规则"。
- 它不是对科学预测的主张：本文严格定位为工程方法论与产业路线图，任何将其解读为"预测个体"的说法，都超出了本文的主张范围。

厘清这三点，有助于把讨论聚焦在真正可检验的问题上：覆盖是否完备、锚定是否唯一、组合是否确定、边界是否清晰。

4 分层架构

本节给出坍定律的分层架构：自下而上依次为静态基座层、动态组合层、执行层与验证层，接口与数据流贯穿其间；各层的职责与相互关系如图 4 所示。

图 3 分层架构：静态基座 → 动态组合 → 执行 → 验证



图 4 分层架构：静态基座 → 动态组合 → 执行 → 验证

4.1 静态基座层

静态基座层是一个有限、可穷举的离散特征矩阵，其元素是离散化的行为/决策特征原型。该矩阵由若干相互正交的控制变量交叉构成：每个变量取固定的取值范围，其笛卡尔积给出有限且完备的状态空间。

这一设计有两点关键性质：

- 覆盖完备性：矩阵在理论上覆盖目标空间，任意样本进入后都能找到其归属的原型；
- 唯一映射：正交性保证不同原型之间不产生交叉重叠，从而映射点唯一。

需要强调：静态基座层是底层特征向量（Base Vector），是"骨架"，而非最终呈现给用户的文本或结果。它类似于基因组中有限的编码单元——编码单元数量有限，却能组合出数量级更大的个体差异。基座层的价值在于：它以有限的状态空间，换取了可穷举、可审计、可复用的确定性起点。一个设计良好的基座层，应当在"足够细"与"可穷举"之间取得平衡：过粗则映射失真，过细则穷举成本失控。

4.2 动态组合层

动态组合层在静态基座之上，引入实时上下文（Context）、时间维度（Time-series）与用户/任务自述，把有限的基座展开为数量级更大的个性化图谱。其核心机制可概括为：

个性化图谱 = 基座骨架 × 实时上下文 × 时间序列 × 个体自述

与基座层的"有限穷举"不同，动态层的展开是组合式的：它不新增底层单元，而是通过显式、可版本化的组合规则，把既有单元与实时输入拼装为具体结果。这一层是把"确定性的骨架"落地为"个性化的输出"的关键。它同时是隐私友好的：系统只需极少的客观参数完成锚定，无需上传敏感数据，即可在组合层展开个体化输出。

4.3 执行层

执行层负责把离散结果转化为可交付的形式：

- 内容场景：由确定性引擎输出结构化内容，再由连续模型承担润色与交互；
- 具身场景：把离散指令转为连续控制（如 MPC、扩散策略、强化学习策略）。

执行层体现的正是"离散为骨、连续为肉"的分工：离散层决定"做什么"，连续层决定"怎么做"。这一分工也界定了错误归因的方向：结构错误应在离散层排查，执行误差应在连续层排查。

4.4 验证层

验证层承担一致性校验、安全约束与合规审核，其目标是使系统可审核、可追溯、可回滚。因为组合规则是显式的、可版本化的，验证层可以对每一次输出追根溯源，并在必要时回滚到既有规则版本。这是纯黑箱范式难以提供的工程属性。

验证层同时是"确定性"承诺的兑现机制：只有当规则可版本化、输出可复现时，"同输入同结构"才不只是口号，而是可被审计的工程事实。

4.5 接口与数据流

系统的端到端数据流为：

输入 → 锚定 → 检索 → 拼装 → 输出

- 输入：极少的客观参数/任务状态；
- 锚定：映射到离散状态（唯一拓扑点）；
- 检索：从矩阵/技能库提取相关单元；
- 拼装：按规则组合单元与上下文；
- 输出：确定性结构 + 连续执行指令。

这一数据流的关键特征是每一步都可被单独观测与测试：锚定是否唯一、检索是否命中、拼装是否合规、输出是否复现，均可独立度量。这与端到端黑箱的"只能看输入输出"形成鲜明对照（端到端数据流如图 5 所示）。

图 4 端到端数据流

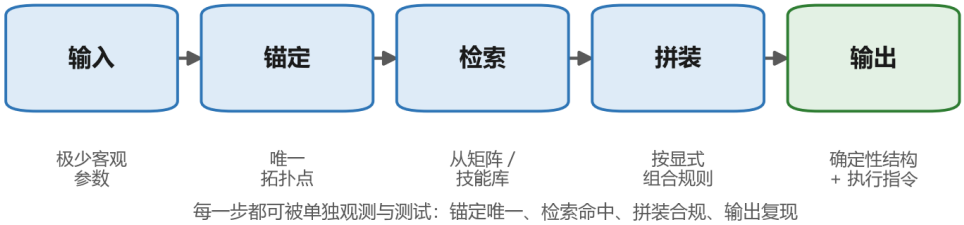


图 5 端到端数据流

4.6 架构的演化路径

分层架构并非一次性建成，而是分阶段演化的：早期以静态基座层与动态组合层为主，验证"离散映射 + 确定性组合"的最小闭环；中期引入执行层与验证层的标准化接口，使离散单元可跨场景复用；远期把四层与在线感知接地整合为完整栈。每一阶段的完成，都以对应的坍 profile 指标达标为标志。这种"分阶段、可验收"的演化方式，使范式的推进不依赖于一次性的技术跃迁。

5 度量体系

塝定律要成为可工程化、可证伪的原则，必须有硬核度量。我们提出如下六类，并给出各类的度量方式。

为使其可操作，本节给出各度量的计算口径与目标值。本文以分层塝 profile（5.6）为主度量，其余五类为辅助度量；目标值为待验证的工程目标（用于定义"验收线"），不代表当前已达到。

- 覆盖率 = 落入 S 的目标样本数 / 目标集样本数，目标 ≥ 95%；
- 唯一映射率 = 唯一锚定的样本数 / 总样本数，目标 ≥ 99%；
- 交叉重叠率 = 冲突映射数 / 总映射数，目标 ≤ 1%；
- 组合泛化率 = 留出组合成功数 / 留出组合总数，目标 ≥ 70%，且须显著优于基线（判据见 7.5）；
- 路径长度 = 从锚定到输出的组合步数，目标 ≤ L_max（依任务时延预算设定）；
- 剪枝效率 = 未剪枝搜索空间 / 实际搜索空间；
- 同输入同结构一致率 = 结构一致的重复次数 / 重复次数，目标 ≥ 99.9%；
- 检索时延、算力与能耗节省：相对连续推理的比值。

5.1 覆盖完备性

- 覆盖率：离散空间对目标人群/任务集的覆盖比例；
- 唯一映射率：输入能被唯一锚定的比例；
- 交叉重叠率：不同原型/技能之间发生冲突的比例。

度量方式：以抽样样本做锚定测试，统计落入定义域内、且映射唯一、且不冲突的比例；覆盖率可用大样本随机抽样逼近。

5.2 组合能力

- 组合泛化率：训练中未出现的新任务组合的成功率；
- 路径长度：从锚定到输出的组合步数；
- 剪枝效率：搜索空间的压缩比。

度量方式：构造留出的组合测试集，比较模型在"见过组合"与"未见组合"上的成功率落差；落差越小，组合泛化越强。

5.3 确定性

- 同输入同结构一致率：同一输入多次调用，输出结构一致的比例；
- 可审核率、可追溯率：输出能被完整溯源的比例；
- 规则版本回滚成功率：规则回滚后系统保持一致的可靠性。

度量方式：对同一输入重复调用 N 次，统计输出结构（而非仅语义）的完全一致比例；溯源可通过对规则版本的显式记录直接验证。

5.4 效率

- 检索时延、算力节省、能耗节省：相对连续推理的对应指标；

- 实时性：能否在具身控制周期内完成组合。

度量方式：在同一硬件与任务上，对照"连续前推"与"检索+拼装"两条路径的时延与能耗。

5.5 任务效果

- 具身指标：任务成功率、安全违规率、人工接管率；
- 内容指标：参与度、留存、付费意愿。

度量方式：具身侧用标准化任务集与真机测试；内容侧用 A/B 对照与产品指标，并明确其定位为个性化内容与自我探索，而非科学预测。

5.6 垮 profile 基准

单一标量不足以刻画多层系统。我们提出垮 profile 基准：一组暴露系统各层主导垮与剩余余量的向量。其用途在于——主导垮层即下一投资重点。当单元层的垮成为瓶颈时，应投资单元设计与覆盖；当技能层的垮成为瓶颈时，应投资组合算法与路径优化。垮 profile 使"下一步该投哪里"成为一个可被数据回答的问题，而非依赖直觉的资源分配。

6 技术路径与关键构件

6.1 坿离散单元

坿离散单元是离散组合空间的基本元素。它至少可包含以下候选形态：

- 原子技能：可独立执行的最小动作/操作单元；
- 符号谓词：可判定的状态/关系描述；
- 特征原型：离散化的行为/决策特征基元；
- 预计算嵌入：预先计算并固化的表征单元；
- 状态机节点：离散状态及其转移的显式节点。

定义一个明确的"坿离散单元"，是使离散组合可设计、可复用的前提。不同场景可选用不同形态，但都需满足：可独立寻址、可显式组合、可被审计。

6.2 正交变量体系

用数学上相互正交的控制变量构建离散空间，是保证覆盖完备性与映射唯一性的关键。正交性使各变量可独立组合而不产生冗余或冲突，从而让有限的状态空间获得最大的表达能力。

待验证：正交性是否经独立的数学证明？各变量的取值范围是否真能覆盖目标全集？这一问题需要独立数学证明与大规模抽样验证，是坿定律成立与否的关键判据之一。

6.3 锚定函数

锚定函数把极少客观参数映射到唯一拓扑点。其设计要求是稳定、抗噪、边界明确。

待验证：锚定的稳定性、抗噪性与边界情况（如处于原型交界处的样本）需要系统检验。若锚定不稳定，则"确定性"在入口处即被破坏。

6.4 检索与组合算法

从矩阵/技能库中提取单元并按规则拼装，需要解决组合爆炸、剪枝与启发式搜索等问题。其目标是：在可接受的时延内，找到满足约束的组合路径。这一环节的效率，直接决定"检索+拼装"能否在实时场景中替代"前推生成"。

6.5 确定性引擎

确定性引擎保证"同样输入→同样结构"。其工程要求包括：规则显式化、可版本化、可回滚、可审计。这是坿定律区别于概率范式的核心工程属性。确定性引擎不是"更小的模型"，而是结构上不同的系统：它的输出由规则而非采样决定。

6.6 混合架构的边界

混合架构并非"处处混合"，其适用边界需明确：

- 封闭任务集：状态空间可穷举、规则可显式化 → 适合纯离散；
- 开放环境：存在大量未被离散化覆盖的连续量 → 需连续推理接地。

识别"何时可纯离散、何时必须接地"，是工程落地的核心判断。一个实用的经验判据是：若任务的成败主要取决于"选对哪一个离散解"，则适合离散；若主要取决于"把解执行得足够精细"，则必须依赖连续接地。

6.7 从设计到落地的检查清单

把塝定律落到工程，可对照一份最小检查清单：

1. 单元：塝离散单元是否可独立寻址、可显式组合、可被审计？
2. 覆盖：正交变量是否覆盖目标全集？是否存在未定义区？
3. 锚定：是否存在输入无法唯一锚定的情况？交界样本如何处理？
4. 组合：组合算法能否在目标时延内完成？剪枝是否有效？
5. 确定性：同输入是否稳定得到同结构？规则是否可版本化、可回滚？
6. 边界：哪些环节必须依赖连续接地？接地的误差如何约束？

这份清单的价值在于，它把抽象原则转译为可逐项检验的工程动作，使"塝定律"不止于一个口号，而成为可被工程团队逐条验收的规范。

7 验证方案与证据基础

本章给出验证设计与证据基础。证据分两类：其一为第三方公开研究的数据（表 1），用以刻画连续向量范式的既有局限；其二为本系统在真实场景中的早期试点记录（图 6），用以说明离散组合系统的可运行性与可核对性。凡引用外部数据，均明确标注来源；试点数据仅以聚合口径呈现，不含任何个体可识别信息。

表 1 相关研究的代表性数据

研究	场景	关键数据
Lin et al., 2022（TruthfulQA）	内容真实性	最强模型真实性 58%，人类 94%
Ji et al., 2023；Huang et al., 2023	幻觉综述	幻觉是生成式模型的系统性特征，而非偶发错误
Lewis et al., 2020（RAG）	检索增强	检索显著改善知识密集型任务的事实性
Brohan et al., 2022（RT-1）	真机多任务	700 余条熟悉指令成功率 97%
Brohan et al., 2023（RT-2）	未见任务泛化	未见任务成功率由 RT-1 的 32% 升至 62%
Lake & Baroni, 2018（SCAN）	系统性泛化	序列到序列模型难以学会组合规则

7.1 内容/自我探索场景：早期试点

连续模型在个体决策辅助中的局限，已有公开证据。Lin 等在 TruthfulQA 上的评测显示，当时最强模型的真实性仅为 58%，而人类为 94%（Lin et al., 2022）；Ji 等与 Huang 等的综述进一步指出，幻觉是生成式模型的系统性特征，而非偶发错误（Ji et al., 2023；Huang et al., 2023）。检索增强虽可改善知识密集型任务的事实性（Lewis et al., 2020），但仍处在连续生成框架之内。

与上述外部证据相对，本系统已在一个真实场景中运行，并留下可核对的记录。试点于 2026-08-28 至 09-13 进行，共 8 位体验者、17 天：系统每日推送状态卡，体验者逐方面反馈"是否符合"，判定记录全程留存、可追溯。主要结果为：总记录 130，状态发送率 100%，反馈响应率 98.5%，核对符合率 97.1%；在 1536 个方面判定点上，完全符合 1481 个（96.4%），非完全符合 55 个（3.6%）。上述指标汇总于图 6（仅聚合口径）。

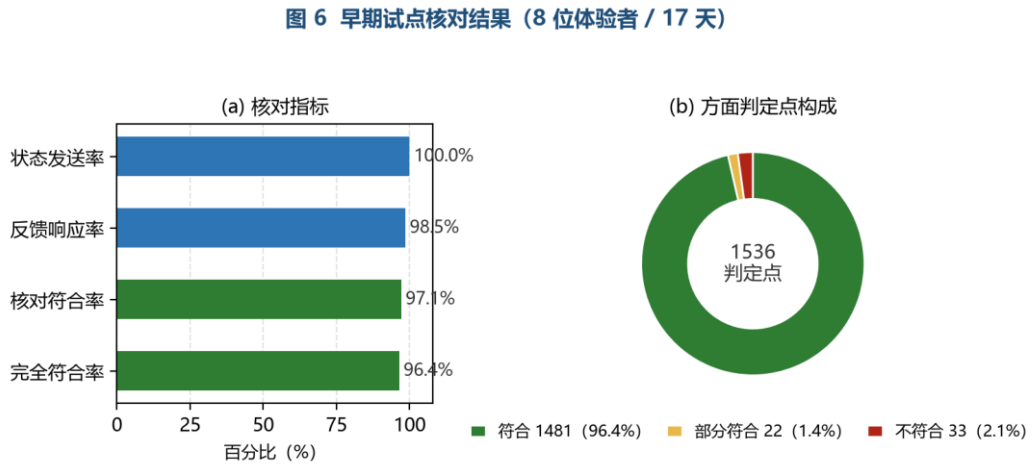


图 6 早期试点核对结果（8 位体验者 / 17 天）

对 55 条非完全符合的归因显示，其主要成因并非"状态不达标"，而是"信息差 × 理解力"的判定口径分歧：对同一词汇（如"秩序""氛围"）的判定边界不同、以长期印象覆盖当日感受、缺少可感受的场景、把整体与当下混淆等；其中约半数集中于单一体验者，属个体差异下的口径分歧，而非普遍性的状态波动。这一现象有两重意义：其一，它印证了可审核、可追溯的价值——每一条不符都可被定位到具体方面与归因；其二，它暴露了符号接地的语义边界（详见 9.2），提示离散单元需要更可操作的判定定义。

需要强调边界：该试点样本量很小（8 人 × 17 天），仅构成早期观察，不构成验证结论；其中的"符合率"是产品侧的一致性指标，用于衡量输出与体验者当日自述状态的一致程度，不构成对个体的科学预测。系统的定位仍严格限定为个性化内容与自我探索。

后续的对照验证设计为：以 A/B 方式对照连续模型基线，比较一致性、留存、付费与满意度，并以参与度、留存与付费意愿衡量用户价值。

7.2 具身智能仿真

具身领域同样有可援引的数据。RT-1 在 700 余条熟悉指令上取得了 97% 的成功率，但其泛化能力有限（Brohan et al., 2022）；RT-2 进一步把"未见（emergent）"任务的成功率从 RT-1 的 32% 提升至 62%（Brohan et al., 2023）。这组数据说明：端到端模型在熟悉任务上已接近饱和，而在"未见组合"上仍有明显落差——正是垺定律主张以离散单元与显式组合规则加以弥补之处。认知科学一侧亦有佐证：在 SCAN 等系统性泛化基准上，序列到序列模型难以学会组合规则（Lake & Baroni, 2018）。

据此，仿真验证的重点是：在留出的组合测试集上，比较离散组合方案与端到端 VLA、分层强化学习、检索增强连续模型、行为树等基线的成功率落差。

7.3 真机验证

真机侧，RT-1 已在真实机器人上验证了大规模多任务的可执行性（Brohan et al., 2022）；扩散策略、低成本双臂操作（ALOHA/ACT）等方法则在底层连续控制上证明了有效性（Chi et al., 2023；Zhao et al., 2023）。这支持"离散规划 + 连续执行"的分工：离散层决定"做什么"，连续层决定"怎么做"。真机验证将围绕抓取、开门、倒水等技能组合，重点检

验安全约束、实时性与人工接管率。真机验证的核心是安全：离散跳转是否可能绕过连续安全约束，需要在真机上被检验而非假设。

7.4 第三方审计

包括正交性的独立数学证明、覆盖率的抽样验证、规则白皮书与语料库审计。第三方审计是塝定律从"工程主张"走向"可被同行检验的原则"的必要环节。没有第三方审计，塝定律就只是一家之言。

7.5 可证伪假设与失败判据

我们明确给出失败判据，以保持原则的可证伪性：

- 若组合泛化率不显著优于最强基线，则本原则的理论增量有限；
- 若符号接地误差导致安全违规，则纯离散路径在开放环境中不可行，必须依赖连续接地。

为避免"显著"一词的模糊，本文给出可操作定义：在留出集上，离散组合的成功率相对最强基线提升 $\geq$ 10 个百分点，且配对检验 $p < 0.05$，方视为"显著优于"；若仅统计显著而效应量 $<$ 10 个百分点，视为"增量有限"。

更根本地，本文承认一种可能：若正交性被证伪——即存在强相关的变量对，使覆盖完备性与唯一映射不成立——则塝定律在理论上不成立，而非仅需"更多研究"。这是本原则最需优先检验、也最可能被推翻的前提。

提出失败判据不是自我否定，而是把原则置于可被检验的位置。一条不可被证伪的原则，不是科学意义上的原则。

8 落地场景与路线图

8.1 近期（2026 – 2028）：个性化内容与自我探索

以离散特征矩阵 + 动态图谱 + 确定性引擎，解决连续模型在个体决策辅助中的"正确的废话"与幻觉问题。连续模型负责润色与交互，规则引擎负责一致性校验。壁垒在于规则细节、大规模高质量语料与用户数据的长期积累。此阶段的成功标准不是"更聪明"，而是"更稳定、更可复现、更可审计"。

8.2 中期（2028 – 2031）：具身智能高层规划

把离散组合用于任务规划、技能编排与长程决策；底层保留连续控制。此阶段的关键是建立技能库与组合规则的标准，使离散单元与组合路径可跨系统复用。这一标准化的意义，类似于为具身智能建立一套"可移植的离散接口"。

8.3 远期（2031 – 2035）：全栈混合

高层离散组合 + 中层混合技能选择 + 底层连续控制 + 在线感知接地，形成"离散为骨、连续为肉"的完整栈。目标：组合泛化、安全可审计、低算力实时。

8.4 标志性目标

如同任何技术路线都需要一个可被检验的"量产验证"，塺定律也需要标志性目标：给出组合泛化率、一致率、任务成功率的硬数据，使原则接受产业界与学术界的公开检验。在标志性目标达成之前，本文的一切主张都应被视为待验证的工程假设，而非既成结论。

为避免路线图停留于定性描述，本文给出可验收的量化里程碑（均为待验证目标，非实测结果；资源与责任主体需产业协作确定，见 8.5；整体路线图如图 7 所示）。

表 2 量化里程碑

时间	可验收指标（目标值）
2027	覆盖率 ≥ 95%；唯一映射率 ≥ 99%；一致率 ≥ 99.9%
2029	组合泛化率 ≥ 70%（须显著优于基线）；具身仿真任务成功率 ≥ 90%
2031	真机任务成功率 ≥ 95%；人工接管率 ≤ 5%
2035	全栈混合：组合泛化率 ≥ 85%；安全违规率趋近于 0

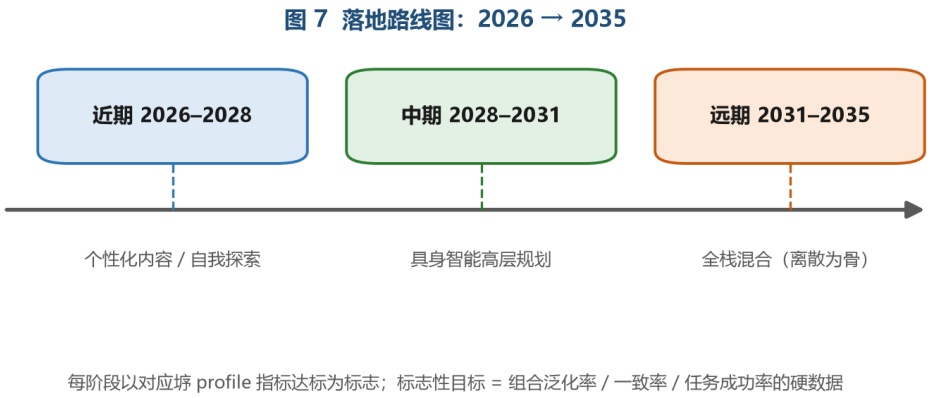


图 7 落地路线图：2026 → 2035

8.5 组织与协作模式

塝定律的落地，对组织形态也提出要求：它需要"单元设计者—组合规则设计者—系统架构师"之间的紧密协同，而非单纯的模型团队。工具链、标准与基准的建立，更是超出单一组织能力的协作议题。因此，本文呼吁以开放协作的方式推进——由多方共同定义离散单元的接口规范、共同维护基准、共同开展第三方审计。唯有如此，塝定律才可能从一家之经验，成长为一个可被广泛检验与复用的公共范式。

9 开放挑战

9.1 组合爆炸

技能/特征单元增多时，组合空间指数增长，需要高效搜索、剪枝与启发式方法。若组合算法不能有效剪枝，则"检索+拼装"的成本优势将被组合爆炸抵消。可行的方向包括：束搜索与 A* 等启发式搜索、基于单元层级的分层剪枝，以及用数据学习剪枝启发式；其复杂度上界与实时性预算需在具体任务上量化。

9.2 符号接地与连续信息损失

离散符号如何与连续物理世界实时对齐？感知符号化会丢失力控、柔顺、接触等连续量，如何在离散框架中保留这些信息，是核心难题。这决定了纯离散路径能走多远。一种可行的接口是"接地层"：离散符号经一个轻量的连续解码器映射为连续控制量，并保留力控、柔顺等连续反馈用于闭环校正。

9.3 正交性与覆盖完备性验证

正交变量是否真正正交？状态空间是否真正穷尽？这需要独立的数学证明与抽样验证。这是坍定律最根本的科学前提，也是最早应被检验的假设。

在证明完成之前，本文按"近似正交"处理：给出变量间的相关性矩阵（Pearson 或 Spearman），以最大相关绝对值作为正交性的近似指标；并给出可操作的替代方案——若无法完全正交，则以相关性矩阵为约束，用"覆盖去重 + 冲突消解"规则弥补，并在论文与产品口径中如实标注"近似覆盖"，而非宣称完全覆盖。

9.4 科学基础与合规伦理

离散特征矩阵的构造依据需要在科学上保持审慎。系统应严格定位为内容与自我探索，而非诊断与预测；若表述暗示预测能力，则可能滑向伪科学或资质合规风险。这是本文反复强调的硬边界。技术上的可解释，不等于科学上的可证实——二者必须严格区分。

9.5 工具链与生态

需要坍原生（坍-native）的工具链：离散组合设计、仿真、验证与部署。标准接口、语料库与评估体系均需重构。工具链的成熟度，往往决定一个范式能否从论文走向产业。

9.6 能量与安全

离散跳转可能绕过连续安全约束，需要配套的能量预算机制与安全层。当系统以"跳转"而非"渐变"改变状态时，中间过渡态被省略，安全性需被重新论证。一种可行设计是"安全层"（shield）：在离散跳转执行前，用连续动力学模型校验其安全性，越界则拒绝或降级为连续控制。

9.7 基准缺失

当前基准不足以指导坍定律。需要坍 profile 基准，暴露每层主导坍与余量，使"下一步该投哪里"可被度量回答。没有适配的基准，范式的进展就缺乏统一标尺。

9.8 时间与成本风险

范式转换并非无风险。离散空间的构建需要长期的语料与规则积累，短期难以见效；工具链的重建需要跨组织投入；若市场对"确定性"的支付意愿不足，则商业闭环可能迟迟无法形成。正视这些风险，是理性推进的前提——它提醒我们，换坐标是一次需要耐心的长跑，而非一次投机的短跑。

10 结论：从规则接受者到规则制定者

10.1 核心主张

塝定律是以离散组合替代连续向量推理的系统演进原则：用有限穷举的状态空间、确定性的检索拼装、可审核的组合规则，换取可解释、低算力、高一致性的输出。

10.2 方法论贡献

- 换坐标：从连续向量空间到离散组合空间；
- 分层：单元、技能、任务、系统四层统一度量；
- 混合：离散为骨，连续为肉。

10.3 产业意义

- 可解释与安全：离散规则可审核、可追溯，适合安全关键场景；
- 隐私优势：只需极少客观参数，不依赖敏感数据，利于合规；
- 低算力与实时性：检索+拼装替代大规模前推，降低推理成本；
- 换坐标即换竞争维度：若该范式成立，将开辟一条不依赖无限放大模型的演进路径。

10.4 邀请协作

未来十年，塝定律的工作清单是明确的，而其中没有任何一项可以由单一组织独立完成：工具链、标准、基准、语料库与安全验证，都需要产业界的共同参与。 因此，本文既是一份来自工程一线的报告，也是一份邀请。

我们清楚地知道，本文提出的许多主张仍处于"理论推演"阶段，尚未完成工程验证与第三方审计。但方向是明确的：当连续向量范式的边际收益开始衰减时，把优化目标切换到离散组合空间，是一条值得认真对待的路径。道路是艰巨的，而起点就在脚下。

10.5 展望

如果把过去十年的主线概括为"在连续向量空间中把模型做大"，那么未来十年的一条主线，可能是在离散组合空间中把系统做"准"。二者并非对立：连续提供感知与执行的柔度，离散提供决策与审计的确定性。当二者以"离散为骨、连续为肉"的方式合流，人工具身智能才可能同时获得泛化能力与工程可信性。

参考文献

[1] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017: 5998-6008.

[2] BROWN T B, MANN B, RYDER N, et al. Language models are few-shot learners[C]//Advances in Neural Information Processing Systems (NeurIPS). 2020: 1877-1901.

[3] JI Z, LEE N, FRIESKE R, et al. Survey of hallucination in natural language generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.

[4] HUANG L, YU W, MA W, et al. A survey on hallucination in large language models: principles, taxonomy, challenges, and open questions[J]. arXiv preprint, 2023, arXiv:2311.05232.

[5] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]//Advances in Neural Information Processing Systems (NeurIPS). 2020: 9459-9474.

[6] FODOR J A, PYLYSHYN Z W. Connectionism and cognitive architecture: a critical analysis[J]. Cognition, 1988, 28(1-2): 3-71.

[7] MARCUS G F. The algebraic mind: integrating connectionism and cognitive science[M]. Cambridge: MIT Press, 2001.

[8] LAKE B M, BARONI M. Generalization without systematicity: on the compositional skills of sequence-to-sequence recurrent networks[C]//Proceedings of the 35th International Conference on Machine Learning (ICML). 2018: 2873-2882.

[9] NEWELL A, SIMON H A. Computer science as empirical inquiry: symbols and search[J]. Communications of the ACM, 1976, 19(3): 113-126.

[10] HOROWITZ M. Computing's energy problem (and what we can do about it)[C]//IEEE International Solid-State Circuits Conference (ISSCC) Digest of Technical Papers. 2014: 10-14.

[11] BROHAN A, BROWN N, CARBAJAL J, et al. RT-1: robotics transformer for real-world control at scale[J]. arXiv preprint, 2022, arXiv:2212.06817.

[12] BROOKS R A. Elephants don't play chess[J]. Robotics and Autonomous Systems, 1990, 6(1-2): 3-15.

[13] LIN S, HILTON J, EVANS O. TruthfulQA: measuring how models mimic human falsehoods[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (ACL). 2022: 3214-3252.

[14] BROHAN A, BROWN N, CARBAJAL J, et al. RT-2: vision-language-action models transfer web knowledge to robotic control[C]//Proceedings of the 7th Conference on Robot Learning (CoRL). 2023.

[15] CHI C, FENG S, DU Y, et al. Diffusion policy: visuomotor policy learning via action diffusion[C]//Robotics: Science and Systems (RSS). 2023.

[16] ZHAO T Z, KUMAR V, LEVINE S, et al. Learning fine-grained bimanual manipulation with low-cost hardware[C]//Robotics: Science and Systems (RSS). 2023.